

A decorative graphic on the left side of the slide, consisting of a network of thin, light-blue lines and small circles, resembling a circuit board or a neural network diagram.

LOOKUPAI – KI- BASIERTE PERSONENRECHERCH E

PROJEKTVORSTELLUNG & TECHNOLOGIEPLAN

HAW HAMBURG – MILESTONE 1

TEAM & ROLLEN

- System Design & Architektur (Entwurf der Systemarchitektur, API-Struktur und Datenflussplanung): Ahmad Kalaf, Jeff Sammy Amevor
- Requirement Engineering (Sammlung und Analyse der Anforderungen, Spezifikation der Systemfunktionen): Afrane Kwame Berquin, Kehan Majeed
- Frontend (UI & Graphical Visualization, Gestaltung und Umsetzung der Benutzeroberfläche, visuelle Darstellung der Ergebnisse): Mubarak Ahmad, Kehan Majeed
- Product Owner (Gesamtkoordination, Zieldefinition, Priorisierung der Anforderungen): Afrane Kwame Berquin
- Backend (Datenanalyse & KI-Logik, Implementierung der Backend-Logik, Datenverarbeitung, KI-Modelle und Schnittstellen): Ahmad Kalaf, Mubarak Ahmad, Jeff Sammy Amevor
- Continuous Integration & Testing (Versionskontrolle, Testautomatisierung, Deployment und Qualitätssicherung): Jeff Sammy Amevor, Kehan Majeed

PROJEKTIDEE

- Ziel: Automatisierte Erstellung geprüfter Kurzbiografien über Geschäftspersonen.
- Problem: Im Internet kursieren viele unzuverlässige Informationen über Personen.
- Lösung: LookUpAI durchsucht öffentliche Quellen (Handelsregister, Firmenwebseiten, Google-Ergebnisse), bewertet deren Glaubwürdigkeit und erstellt strukturierte Fact Sheets (z. B. PDF).
- Einsatzgebiet: Vertriebs- und Research-Abteilungen, Recruiting usw.

ZIELGRUPPE & NUTZEN

- Unternehmen, die schnell verlässliche Hintergrundinformationen benötigen.
 - Recruiter und Analysten, die Personenprofile prüfen müssen.
 - Studierende und Journalisten für Recherchezwecke.
 - Allgemein Menschen, die sich über den Hintergrund (Lebenslauf) einer anderen Person informieren möchten
- Zeitersparnis, Transparenz, faktenbasierte Entscheidungen.

PROJEKTPLAN

Milestone 1 – Projektplan und Technologie

- Tech Stack festlegen (Python, n8n, PostgreSQL)
- Projektstruktur, Verantwortlichkeiten und Workflows in n8n definieren

Milestone 2 – erster Prototyp

- CSV-Upload und Validierung über n8n-Workflow implementieren
- Einfaches Scraping (1–2 Quellen pro Person) mit n8n-Nodes oder Python-Skripten
- Regelbasierte Informationsextraktion (Name, Firma, Rolle) in Python- oder Code-Nodes
- Erste PDF-Generierung aus HTML über n8n-Workflow (anstatt WeasyPrint direkt)
- Automatische Tests und Versionskontrolle via pytest & GitHub-Integration

Milestone 3 – zweiter Prototyp

- Erweiterung der Pipeline auf mehrere Quellen (automatisiert in n8n)
- Einführung einer einfachen Bewertung von Quellen (Confidence Score)
- Datenbank-Anbindung (PostgreSQL für Fakten und Rohdaten, über n8n-Nodes)
- Vorbereitung auf LLM-Integration in späteren Prototypen (z. B. via API-Aufrufe in n8n)

TECHNOLOGIEÜBERSICHT

➤ **Python 3.11+**

Hauptsprache – genutzt für individuelle Skripte, KI-Modelle & Spezialverarbeitung.

➤ **n8n (Workflow-Automatisierung & Orchestrierung)**

Zentrale Steuerung der gesamten Pipeline:

automatisiert Web-Scraping, Datenextraktion, Verarbeitung & PDF-Erstellung.

ersetzt Teile von FastAPI, Playwright/BeautifulSoup, SQLAlchemy und WeasyPrint.

führt Python-Code, KI-Modelle und Datenbankaktionen direkt in Workflows aus.

➤ **PostgreSQL (Datenhaltung)**

Dient als persistente Speicher- und Abrufschicht für strukturierte Fakten & Quellen.

n8n interagiert direkt über integrierte PostgreSQL-Nodes.

➤ **pytest, black, ruff, GitHub**

Bleiben zur Sicherstellung von Code-Qualität, Tests & Team-Kollaboration erhalten.

DATENFLUSS (BEISPIEL)

- 1. Benutzer lädt CSV mit Namen hoch.
- 2. FastAPI validiert Eingabe und startet Pipeline.
- 3. Scraper (Playwright) ruft öffentliche Quellen auf.
- 4. Text wird bereinigt, Fakten per Regex erkannt.
- 5. PDF-Fact Sheet wird generiert und gespeichert.
- 6. Ergebnis abrufbar über Web-Interface.

RISIKEN & GEGENMAßNAHMEN

- Scraping-Fehler → Retry-Mechanismen, Logging, Timeout.
- Datenqualität → Bewertung der Quellen (Confidence Score).
- Datenschutz (DSGVO) → Nur öffentliche Quellen, keine PII-Logs.
- Zeitplanrisiko → Agile Entwicklung mit klaren Milestones.

AUSBLICK & VISION

- Ausbau zu einem intelligenten OSINT-Agenten-System.
- LLM-Integration zur automatischen Textzusammenfassung.
- Dashboard mit Echtzeit-Status & Quellenanalyse.
- Open-Source-Basis für Forschung und Lehrzwecke an der HAW Hamburg.