

A decorative graphic on the left side of the slide, consisting of a network of thin, light blue lines and small circles, resembling a circuit board or a neural network diagram.

LOOKUPAI – KI- BASIERTE PERSONENRECHERCH E

PROJEKTVORSTELLUNG & TECHNOLOGIEPLAN

HAW HAMBURG – MILESTONE 1

TEAM & ROLLEN

- System Design & Architektur (Entwurf der Systemarchitektur, API-Struktur und Datenflussplanung): Ahmad Kalaf, Jeff Sammy Amevor
- Requirement Engineering (Sammlung und Analyse der Anforderungen, Spezifikation der Systemfunktionen): Afrane Kwame Berquin, Kehan Majeed
- Frontend (UI & Graphical Visualization, Gestaltung und Umsetzung der Benutzeroberfläche, visuelle Darstellung der Ergebnisse): Mubarak Ahmad, Kehan Majeed
- Product Owner (Gesamtkoordination, Zieldefinition, Priorisierung der Anforderungen): Afrane Kwame Berquin
- Backend (Datenanalyse & KI-Logik, Implementierung der Backend-Logik, Datenverarbeitung, KI-Modelle und Schnittstellen): Ahmad Kalaf, Mubarak Ahmad, Jeff Sammy Amevor
- Continuous Integration & Testing (Versionskontrolle, Testautomatisierung, Deployment und Qualitätssicherung): Jeff Sammy Amevor, Kehan Majeed

PROJEKTIDEE

- Ziel: Automatisierte Erstellung geprüfter Kurzbiografien über Geschäftspersonen.
- Problem: Im Internet kursieren viele unzuverlässige Informationen über Personen.
- Lösung: LookUpAI durchsucht öffentliche Quellen (Handelsregister, Firmenwebseiten, Google-Ergebnisse), bewertet deren Glaubwürdigkeit und erstellt strukturierte Fact Sheets (z. B. PDF).
- Einsatzgebiet: Vertriebs- und Research-Abteilungen, Recruiting usw.

ZIELGRUPPE & NUTZEN

- Unternehmen, die schnell verlässliche Hintergrundinformationen benötigen.
 - Recruiter und Analysten, die Personenprofile prüfen müssen.
 - Studierende und Journalisten für Recherchezwecke.
 - Allgemein Menschen, die sich über den Hintergrund (Lebenslauf) einer anderen Person informieren möchten
- Zeitersparnis, Transparenz, faktenbasierte Entscheidungen.

PROJEKTPLAN

Milestone 1 – Projektplan und Technologie

- Tech Stack festlegen (Python, n8n, PostgreSQL)
- Projektstruktur, Verantwortlichkeiten

Milestone 2 – erster Prototyp

- CSV-Upload und Validierung über n8n-Workflow implementieren
- Einfaches Scraping (1–2 Quellen pro Person) mit n8n-Nodes oder Python-Skripten
- Regelbasierte Informationsextraktion (Name, Firma, Rolle) in Python- oder Code-Nodes
- Erste PDF-Generierung aus HTML über n8n-Workflow (anstatt WeasyPrint direkt)
- Automatische Tests und Versionskontrolle via pytest & GitHub-Integration

Milestone 3 – zweiter Prototyp

- Erweiterung der Pipeline auf mehrere Quellen (automatisiert in n8n)
- Einführung einer einfachen Bewertung von Quellen (Confidence Score)
- Datenbank-Anbindung (PostgreSQL für Fakten und Rohdaten, über n8n-Nodes)
- Vorbereitung auf LLM-Integration in späteren Prototypen (z. B. via API-Aufrufe in n8n)

TECHNOLOGIEÜBERSICHT

➤ **Python 3.11+**

Hauptsprache – genutzt für individuelle Skripte, KI-Modelle & Spezialverarbeitung.

➤ **n8n (Workflow-Automatisierung & Orchestrierung)**

Zentrale Steuerung der gesamten Pipeline:

automatisiert Web-Scraping, Datenextraktion, Verarbeitung & PDF-Erstellung.

ersetzt Teile von FastAPI, Playwright/BeautifulSoup, SQLAlchemy und WeasyPrint.

führt Python-Code, KI-Modelle und Datenbankaktionen direkt in Workflows aus.

➤ **PostgreSQL (Datenhaltung)**

Dient als persistente Speicher- und Abrufschicht für strukturierte Fakten & Quellen.

n8n interagiert direkt über integrierte PostgreSQL-Nodes.

➤ **pytest, black, ruff, GitHub**

Bleiben zur Sicherstellung von Code-Qualität, Tests & Team-Kollaboration erhalten.

DATENFLUSS (BEISPIEL)

1. Benutzer lädt CSV mit Namen und Suchbegriffen hoch.
2. FastAPI validiert Eingabe und startet Pipeline (n8n Workflow)
3. Scraper (Playwright) ruft öffentliche Quellen auf (n8n Workflow)
4. Text wird bereinigt, Fakten per Regex erkannt.
5. PDF-Fact Sheet wird generiert und gespeichert.
6. Ergebnis abrufbar über Web-Interface.

RISIKEN & GEGENMAßNAHMEN

- Scraping-Fehler → Retry-Mechanismen, Logging, Timeout.
- Datenqualität → Bewertung der Quellen (Confidence Score).
- Datenschutz (DSGVO) → Nur öffentliche Quellen, keine PII-Logs.
- Zeitplanrisiko → Agile Entwicklung mit klaren Milestones.

AUSBLICK & VISION

- Ausbau zu einem intelligenten OSINT-Agenten-System.
- LLM-Integration zur automatischen Textzusammenfassung.
- Dashboard mit Echtzeit-Status & Quellenanalyse.
- Open-Source-Basis für Forschung und Lehrzwecke an der HAW Hamburg.