

A decorative graphic on the left side of the slide, consisting of a network of thin, light blue lines and small circles, resembling a circuit board or a neural network diagram.

LOOKUPAI – KI- BASIERTE PERSONENRECHERCH E

PROJEKTVORSTELLUNG & TECHNOLOGIEPLAN

HAW HAMBURG – MILESTONE 1

TEAM & ROLLEN

- System Design & Architektur (Entwurf der Systemarchitektur, API-Struktur und Datenflussplanung): Ahmad Kalaf, Jeff Sammy Amevor
- Requirement Engineering (Sammlung und Analyse der Anforderungen, Spezifikation der Systemfunktionen): Afrane Kwame Berquin, Kehan Majeed
- Frontend (UI & Graphical Visualization, Gestaltung und Umsetzung der Benutzeroberfläche, visuelle Darstellung der Ergebnisse): Mubarak Ahmad, Kehan Majeed
- Product Owner (Gesamtkoordination, Zieldefinition, Priorisierung der Anforderungen): Afrane Kwame Berquin
- Backend (Datenanalyse & KI-Logik, Implementierung der Backend-Logik, Datenverarbeitung, KI-Modelle und Schnittstellen): Ahmad Kalaf, Mubarak Ahmad, Jeff Sammy Amevor
- Continuous Integration & Testing (Versionskontrolle, Testautomatisierung, Deployment und Qualitätssicherung): Jeff Sammy Amevor, Kehan Majeed

PROJEKTIDEE

- Ziel: Automatisierte Erstellung geprüfter Kurzbiografien über Geschäftspersonen.
- Problem: Im Internet kursieren viele unzuverlässige Informationen über Personen.
- Lösung: LookUpAI durchsucht öffentliche Quellen (Handelsregister, Firmenwebseiten, Google-Ergebnisse), bewertet deren Glaubwürdigkeit und erstellt strukturierte Fact Sheets (z. B. PDF).
- Einsatzgebiet: Vertriebs- und Research-Abteilungen, Recruiting usw.

ZIELGRUPPE & NUTZEN

- Unternehmen, die schnell verlässliche Hintergrundinformationen benötigen.
 - Recruiter und Analysten, die Personenprofile prüfen müssen.
 - Studierende und Journalisten für Recherchezwecke.
 - Allgemein Menschen, die sich über den Hintergrund (Lebenslauf) einer anderen Person informieren möchten
- Zeitersparnis, Transparenz, faktenbasierte Entscheidungen.

PROJEKTPLAN

1. Milestone 1 – Projektplan und Technologie

- Tech Stack festlegen (Python, FastAPI, Playwright, WeasyPrint)
- Projektstruktur und Verantwortlichkeiten festlegen

2. Milestone 2 – erster Prototyp

- CSV-Upload und Validierung implementieren
- Einfaches Scraping (1–2 Quellen pro Person)
- Regelbasierte Informationsextraktion (Name, Firma, Rolle)
- Erste PDF-Generierung mit WeasyPrintUnit- und API-Tests mit pytest

3. Milestone 3 – zweiter Prototyp

- Erweiterung der Pipeline um mehrere Quellen
- Einführung einer einfachen Bewertung von Quellen (Confidence Score)
- Datenbank-Anbindung (PostgreSQL für Fakten und Rohdaten)
- Vorbereitung auf LLM-Integration in späteren Prototypen

TECHNOLOGIEÜBERSICHT

- Python 3.11+

Hauptsprache – ideal für KI, Datenverarbeitung & Web Scraping.

- FastAPI (Backend & REST-API)

Zentrale Schnittstelle: nimmt Eingaben entgegen & steuert Verarbeitung.

- Playwright + BeautifulSoup

Playwright lädt Webseiten automatisiert,

BeautifulSoup filtert & extrahiert relevante Inhalte.

- Information Extraction (IE)

Anfangs Regex-Regeln, später KI-Modelle für komplexere Fakten.

- PostgreSQL + SQLAlchemy

Speicherung strukturierter Fakten & Quellen in der Datenbank.

- WeasyPrint

Erstellt automatisch formatierte PDF-Fact-Sheets aus HTML-Vorlagen.

- pytest, black, ruff, GitHub

Tests, Code-Qualität & Team-Kollaboration bzw. Versionskontrolle.

DATENFLUSS (BEISPIEL)

- 1. Benutzer lädt CSV mit Namen hoch.
- 2. FastAPI validiert Eingabe und startet Pipeline.
- 3. Scraper (Playwright) ruft öffentliche Quellen auf.
- 4. Text wird bereinigt, Fakten per Regex erkannt.
- 5. PDF-Fact Sheet wird generiert und gespeichert.
- 6. Ergebnis abrufbar über Web-Interface.

RISIKEN & GEGENMAßNAHMEN

- Scraping-Fehler → Retry-Mechanismen, Logging, Timeout.
- Datenqualität → Bewertung der Quellen (Confidence Score).
- Datenschutz (DSGVO) → Nur öffentliche Quellen, keine PII-Logs.
- Zeitplanrisiko → Agile Entwicklung mit klaren Milestones.

AUSBLICK & VISION

- Ausbau zu einem intelligenten OSINT-Agenten-System.
- LLM-Integration zur automatischen Textzusammenfassung.
- Dashboard mit Echtzeit-Status & Quellenanalyse.
- Open-Source-Basis für Forschung und Lehrzwecke an der HAW Hamburg.